

PREDICCIÓN DE RIESGO CARDIOVASCULAR EN EE.UU

Presentado por:

Juan Sebastian Garcia

Julian David Sanabria

Wendy Natalia Vega

Laura Daniela Rivera

DataXperience

Facultad de Ingeniería, Universidad EAN

Presentado a :

Camila Silva Gómez

13 de septiembre de 2026

Bogotá D.C

INTRODUCCIÓN

Las enfermedades cardiovasculares se posicionan como la principal causa de mortalidad global, representando un desafío crítico para la salud pública. Mientras que factores no modificables como la edad, el sexo y los antecedentes genéticos dictan un riesgo base, son las variables de estilo de vida —el tabaquismo, la actividad física y los hábitos alimenticios— las que ofrecen la mayor oportunidad para la intervención y la prevención temprana. Comprender qué variables presentan una correlación más sólida con la aparición de patologías cardíacas resulta imperativo para desarrollar estrategias preventivas y políticas de salud adaptadas a las necesidades reales de distintas poblaciones.

En este marco, el presente proyecto se desarrolla para la asignatura **Dataxperience**, con el objetivo de integrar y aplicar de manera práctica las metodologías de análisis de datos, modelado y exploración adquiridas durante el curso. Para este fin, se utiliza el conjunto de datos *Indicators of Heart Disease (2022 UPDATE)*, alojado en Kaggle. Esta base de datos recopila información extraída de la encuesta *Behavioral Risk Factor Surveillance System (BRFSS)*, un sistema de monitoreo telefónico que el CDC (Centro para el Control y la Prevención de Enfermedades de EE. UU.) aplica anualmente a cientos de miles de adultos. A través del procesamiento y análisis de esta fuente, el proyecto busca transformar un volumen robusto de datos observacionales en un modelo capaz de identificar patrones clave e informar decisiones en la detección oportuna de riesgos cardiovasculares.

PLANTEAMIENTO DEL PROBLEMA

¿Cuáles son los factores demográficos, clínicos y conductuales que mejor predicen la presencia de enfermedad cardíaca en adultos? ¿Es posible construir un modelo que, basado en información de encuestas de comportamiento, pueda identificar a personas en riesgo con una exactitud aceptable?

OBJETIVOS

OBJETIVO GENERAL

Analizar los factores demográficos, clínicos y conductuales asociados a la enfermedad cardíaca, y construir un modelo capaz de predecir la probabilidad de que una persona haya padecido enfermedad cardíaca, basado en la encuesta BRFSS 2022.

OBJETIVOS ESPECÍFICOS

- ★ Limpiar, validar y preparar la base de datos siguiendo el ciclo completo de preprocesamiento.
- ★ Caracterizar la muestra mediante análisis estadístico descriptivo de las variables numéricas y categóricas.
- ★ Explorar las relaciones entre variables clínicas/conductuales y la enfermedad cardíaca mediante EDA y pruebas estadísticas.
- ★ Entrenar y comparar modelos de clasificación (Regresión Logística y Random Forest).
- ★ Evaluar el desempeño del modelo e interpretar los factores de mayor importancia.
- ★ Formular conclusiones y recomendaciones aplicables a políticas de salud pública.

BÚSQUEDA Y OBTENCIÓN DE DATOS

Nuestra fuente corresponde a Indicators of Heart Disease (2022 UPDATE), publicado en Kaggle a partir de la encuesta anual BRFSS (Behavioral Risk Factor Surveillance System) que aplica anualmente el CDC (Centro para el Control y Prevención de Enfermedades de EE. UU.) a cientos de miles de adultos por vía telefónica.

JUSTIFICACIÓN DE LA FUENTE

Es una encuesta oficial, de gran tamaño muestral (~445.000 registros) y con variables clínicas, demográficas y de comportamiento ya validadas por el CDC.

Es el mismo tipo de dataset (heart_2022_with_nans.csv) usado como referencia en los recursos de la clase, lo que permite aplicar directamente la metodología de limpieza y análisis vista en el curso.

Contiene valores faltantes reales y variables de distintos tipos (numéricas, categóricas binarias, categóricas multiclase), ideal para demostrar el proceso completo de Ciencia de Datos.

DIMENSIÓN DEL DATASET

- Filas iniciales: 445.132
- Columnas: 40 variables
- Mezcla de variables numéricas, categóricas binarias y categóricas multiclase

CONJUNTO DE DATOS Y DESCRIPCIÓN DE VARIABLES

Primero revisamos la estructura general: tipos de dato, resumen estadístico y significado de cada variable.

Variables Demográficas

- State: Estado de EE.UU. donde vive el encuestado (50 categorías)
- Sex: Sexo biológico (Male / Female)
- AgeCategory: Rango de edad en grupos de 5 años (13 categorías, desde 18-24 hasta 80 o más)
- RaceEthnicityCategory: Grupo étnico/racial del encuestado

Variables de Salud Física y Mental

- GeneralHealth: Percepción propia de salud general (Poor, Fair, Good, Very good, Excellent)
- PhysicalHealthDays: Días en el último mes con mala salud física (0-30)
- MentalHealthDays: Días en el último mes con mala salud mental (0-30)
- SleepHours: Horas de sueño promedio por noche

Variables de Comportamiento y Estilos de Vida

- PhysicalActivities: Realización de actividad física en el último mes (Yes / No)
- SmokerStatus: Estado de fumador (Never, Current, Former smoker)
- ECigaretteUsage: Uso de cigarrillo electrónico
- AlcoholDrinkers: Consumo de alcohol (Yes / No)

Variables de Antropometría

- HeightInMeters: Estatura en metros
- WeightInKilograms: Peso en kilogramos
- BMI: Índice de masa corporal (kg/m^2)

Variables Clínicas (Antecedentes)

- HadHeartAttack: Antecedente de infarto (Yes / No)
- HadAngina: Antecedente de angina (Yes / No)
- HadStroke: Antecedente de accidente cerebrovascular (Yes / No)
- HadDiabetes: Antecedente de diabetes (None, Prediabetes, During pregnancy, Yes)
- HadAsthma, HadCOPD, HadKidneyDisease, HadArthritis, HadDepressiveDisorder, HadSkinCancer

Proceso completo de limpieza y preparación de los datos.

Se sigue el orden:

1. nombres de columnas
2. duplicados exactos
3. texto (espacios/mayúsculas)
4. categorías equivalentes
5. valores imposibles
6. valores faltantes al final.

Etapla 1: Validación de Nombres de Columnas

Se verificó la presencia de espacios, caracteres especiales y mayúsculas inconsistentes en los nombres de las columnas. El archivo del CDC ya viene bien formateado, por lo que no se requirieron cambios, pero el paso queda documentado como control de calidad.

```
# Verificacion: espacios, mayusculas raras, caracteres especiales
print(df.columns.tolist())
df.columns = df.columns.str.strip() # defensivo, por si acaso
print('\nNombres de columnas OK, no se requieren cambios adicionales.')

['State', 'Sex', 'GeneralHealth', 'PhysicalHealthDays', 'MentalHealthDays', 'LastCheckupTime', 'PhysicalActivities']

Nombres de columnas OK, no se requieren cambios adicionales.
```

Etapla 2: Identificación y Eliminación de Duplicados Exactos

Se buscaron filas completamente idénticas en todas sus columnas. El dataset contenía 157 duplicados exactos, por lo que no se eliminaron algunos registros en esta etapa.

```
duplicados_exactos = df.duplicated().sum()
print('Duplicados exactos encontrados:', duplicados_exactos)

df = df.drop_duplicates().reset_index(drop=True)
print('Filas despues de quitar duplicados:', df.shape[0])

Duplicados exactos encontrados: 157
Filas despues de quitar duplicados: 444975
```

Etapla 3: Limpieza de Texto y Normalización de Categorías

Se revisaron todas las columnas de texto en busca de variantes de una misma categoría (ej. "Yes" / "YES" / "yes"). Al revisar los valores únicos de todas las variables categóricas no se

encontraron variantes equivalentes de categorías. El archivo ya había sido estandarizado por el CDC.

```
columnas_texto = df.select_dtypes(include='object').columns
cambios = 0
for col in columnas_texto:
    original = df[col].copy()
    df[col] = df[col].str.strip()
    cambios += ((original != df[col]) & original.notna() & df[col].notna()).sum()

print('Valores de texto con espacios corregidos:', cambios)
print('El archivo del CDC ya viene bien formateado; este paso queda como control de calidad.')
```

Valores de texto con espacios corregidos: 0
(El archivo del CDC ya viene bien formateado; este paso queda como control de calidad.)

Etapa 4: Identificación de Valores Imposibles

Se definieron rangos válidos para variables numéricas según su significado clínico y la formulación original de las preguntas. Los valores fuera de estos rangos se marcaron como valores faltantes (NaN):

	Variable	Rango valido	Valores imposibles
0	PhysicalHealthDays	[0, 30]	0
1	MentalHealthDays	[0, 30]	0
2	SleepHours	[1, 24]	0
3	HeightInMeters	[0.9, 2.3]	10
4	WeightInKilograms	[20, 300]	0
5	BMI	[10, 100]	0

Etapa 5: Gestión de Valores Faltantes (Estrategia Diferenciada)

Se implementó una estrategia distinta según el tipo y porcentaje de faltantes:

a) Variable objetivo (HadHeartAttack, HadAngina): Eliminación de filas

No se imputan. Son la base de la variable que se va a predecir; inventar su valor introduciría sesgo directo. Se eliminaron 3.065 filas con HadHeartAttack nulo y 4.405 con HadAngina nulo.

b) Variables numéricas continuas: Imputación con mediana


PhysicalHealthDays, MentalHealthDays, SleepHours, HeightInMeters, WeightInKilograms, BMI se imputaron con la mediana en lugar de la media, porque todas ellas presentan asimetría — la media se ve arrastrada por los valores extremos, mientras que la mediana es más robusta.

c) Categóricas clínicas/demográficas (<10% faltantes): Imputación con moda

Sex, GeneralHealth, SmokerStatus, AgeCategory, HadDiabetes, HadStroke y otras variables categóricas con missingness bajo fueron imputadas con la moda (categoría más frecuente). Con faltantes bajos, esta aproximación es segura.

d) Categóricas de tamizaje opcional ($\geq 10\%$ faltantes): Categoría explícita "No informado"

ChestScan, HIVTesting, FluVaxLast12, PneumoVaxEver, TetanusLast10Tdap, HighRiskLastYear, CovidPos tienen missingness alto (>10-20%) probablemente porque son preguntas de salto en la encuesta (el faltante puede significar "no aplica" o "no se le preguntó"). Se creó una categoría explícita "No informado" para preservar esta información sin inventar una respuesta.



Resultado Final de Limpieza

- Filas iniciales: 445.132
- Filas después de eliminar nulos en variable objetivo: 437.662
- Valores faltantes totales al final: 0
- Dataset listo para análisis: 437.662×40


Verificación de la Limpieza

Se confirma que el dataset quedó bien limpio antes de seguir con el análisis.

```
print('=== VERIFICACION FINAL DE LIMPIEZA ===')
print('Filas crudas iniciales      : ', 445132)
print('Duplicados exactos quitados : ', duplicados_exactos)
print('Valores imposibles marcados : ', sum(r['Valores imposibles'] for r in reporte_imposibles))
print('Filas finales limpias       : ', df.shape[0])
print('Columnas finales             : ', df.shape[1])
print('Nulos totales                 : ', df.isnull().sum().sum())
print()
for col, (lo, hi) in rangos_validos.items():
    fuera = ((df[col] < lo) | (df[col] > hi)).sum()
    print(f' {col}: valores aun fuera de rango = {fuera}')
```

```
... === VERIFICACION FINAL DE LIMPIEZA ===
Filas crudas iniciales      : 445132
Duplicados exactos quitados : 157
Valores imposibles marcados : 10
Filas finales limpias       : 438327
Columnas finales           : 40
Nulos totales               : 0
```

Análisis exploratorio de datos (EDA).



Distribución Univariante

La variable HeartDisease muestra un desbalance importante:


- Personas SIN enfermedad cardíaca: 91.3% (399.038 registros)
- Personas CON enfermedad cardíaca: 8.7% (38.624 registros)

Esto es clínicamente esperado (no todos tienen un evento cardíaco) pero es una advertencia importante para la etapa de modelado: la exactitud (accuracy) sola puede ser engañosa. Se deben evaluar métricas alternativas: precisión, recall, AUC-ROC.

Enfermedad Cardíaca por Edad

La edad es el factor más determinante:

- Menores de 30 años: < 2% de prevalencia
- 30-49 años: 2-5% de prevalencia
- 50-69 años: 10-15% de prevalencia
- 70-79 años: 15-20% de prevalencia
- 80 años o más: > 20% de prevalencia



Enfermedad Cardíaca por Sexo


Existe una diferencia notable por sexo:


- Hombres: prevalencia 12-14% (significativamente mayor)
- Mujeres: prevalencia 5-7% (significativamente menor)

Enfermedad Cardíaca por Percepción de Salud General

La percepción propia de salud es uno de los predictores categóricos más fuertes:

- Excellent: 1-2%
- Very good: 2-3%
- Good: 5-6%
- Fair: 15-20%
- Poor: 25-30%






Enfermedad Cardíaca por Tabaquismo

El tabaquismo muestra un patrón claro de asociación:


- Nunca fumó: 6-7% (prevalencia más baja)
- Fumador actual: 10-11% (prevalencia intermedia)
- Exfumador: 12-14% (prevalencia más alta)



Enfermedad Cardíaca por Actividad Física

Se observa una clara asociación protectora:

- Con actividad física: 7-8%
- Sin actividad física: 12-13%




BMI (Índice de Masa Corporal)

Las personas con enfermedad cardíaca tienen un BMI significativamente mayor:

- Con enfermedad cardíaca: mediana BMI = 29.5
- Sin enfermedad cardíaca: mediana BMI = 26.8

La diferencia es pequeña en términos absolutos pero estadísticamente significativa en una muestra de casi 450.000 personas.



Análisis estadístico descriptivo

Se calculan las medidas de tendencia central, posición y dispersión para las variables numéricas clave, siguiendo lo visto en la clase de Estadística Descriptiva.

	Media	Mediana	Moda	Q1 (25%)	Q3 (75%)	Rango	Varianza	Desv. estandar	IQR	CV (%)
AgeMidpoint	55.17	57.00	67.00	42.00	67.00	61.00	322.15	17.95	25.00	32.54
BMI	28.40	27.44	27.44	24.41	31.01	87.62	38.28	6.19	6.60	21.78
SleepHours	7.02	7.00	7.00	6.00	8.00	23.00	2.20	1.48	2.00	21.12
PhysicalHealthDays	4.18	0.00	0.00	0.00	3.00	30.00	72.92	8.54	3.00	204.24
MentalHealthDays	4.27	0.00	0.00	0.00	4.00	30.00	68.80	8.29	4.00	194.06
WeightInKilograms	82.85	80.74	80.74	68.04	91.63	269.89	416.31	20.40	23.59	24.63
HeightInMeters	1.70	1.70	1.70	1.63	1.78	1.38	0.01	0.10	0.15	6.09

El coeficiente de variación (CV) más alto lo tienen PhysicalHealthDays y MentalHealthDays: la mayoría de personas reporta 0 días, pero unas reportan hasta 30, generando mucha dispersión relativa a su propia media.

BMI tiene una media de 28.4 más alta que su mediana 27.4: son datos con cola hacia la derecha personas con IMC muy alto que "jalan" la media

Análisis estadístico inferencial

Se realizaron pruebas Chi-Cuadrado para evaluar si cada variable categórica es independiente de la enfermedad cardíaca.

Hipótesis:

- H0 (nula): la variable categórica es independiente de HeartDisease
- H1 (alternativa): existe asociación entre la variable y HeartDisease

	Variable	Chi2	gl	p-valor	Conclusion
3	GeneralHealth	25329.3	4	0.000000e+00	Se rechaza H0 (hay asociacion)
4	HadDiabetes	13874.4	3	0.000000e+00	Se rechaza H0 (hay asociacion)
1	SmokerStatus	4759.4	3	0.000000e+00	Se rechaza H0 (hay asociacion)
2	PhysicalActivities	4030.1	1	0.000000e+00	Se rechaza H0 (hay asociacion)
0	Sex	2138.7	1	0.000000e+00	Se rechaza H0 (hay asociacion)
5	RaceEthnicityCategory	1028.4	4	2.550179e-221	Se rechaza H0 (hay asociacion)

Conclusión: todas las variables categóricas están asociadas de forma estadísticamente significativa con la enfermedad cardíaca. El estadístico χ^2 es especialmente alto para GeneralHealth y HadDiabetes, indicando que son los predictores categóricos más fuertes.

HALLAZGOS, PATRONES E INSIGHTS

A partir del EDA y las pruebas estadísticas anteriores:

1. La edad es el factor más determinante

La prevalencia de enfermedad cardíaca sube de forma casi monótona con la edad, de menos del 2% en menores de 30 años a más del 20% en mayores de 80. Este patrón es consistente con el conocimiento clínico de que el envejecimiento es un factor de riesgo no modificable para enfermedades cardiovasculares.

2. Diferencia significativa por sexo

Los hombres muestran una prevalencia aproximadamente 2 veces más alta que las mujeres (12-14% vs 5-7%). La asociación es significativa (χ^2 alto, $p < 0.001$) y es un hallazgo importante para diseñar intervenciones de salud pública diferenciadas.

3. Percepción de salud general y diabetes: predictores categóricos más fuertes

Dentro del grupo de variables categóricas, GeneralHealth y HadDiabetes tienen el estadístico χ^2 más alto. Las personas que reportan salud "Poor" tienen prevalencia de ~30%, mientras que quienes reportan "Excellent" tienen ~1%. Igualmente, tener diabetes multiplica significativamente el riesgo.

4. El tabaquismo importa, en forma escalonada

Nunca haber fumado está asociado a la menor prevalencia (~6-7%), mientras que ser fumador actual se asocia con la más alta (~12-14%). Los exfumadores están en posición intermedia (~10-11%), consistente con el efecto acumulativo del hábito y con la persistencia de riesgo incluso después de dejar de fumar.

5. La actividad física tiene un efecto protector

Las personas que realizan actividad física reportan una prevalencia más baja (~7-8%) frente a quienes no la realizan (~11-12%). Aunque la diferencia es más moderada que la de edad o diabetes, el efecto es claro y estadísticamente significativo.

6. BMI es significativamente mayor en el grupo con enfermedad cardíaca

Aunque la correlación numérica lineal es débil, la prueba de Mann-Whitney U confirma que la distribución de BMI es significativamente distinta (y más alta) en personas con enfermedad cardíaca.

7. Las correlaciones lineales simples son débiles

Esto sugiere que el riesgo cardíaco no depende de una sola variable numérica de forma lineal, sino de la combinación de múltiples factores (edad, sexo, condiciones clínicas, comportamientos) interactuando. Justifica el uso de un modelo capaz de capturar relaciones no lineales e interacciones.

8. Dataset desbalanceado: necesidad de métricas alternativas a accuracy

Solo el 8.7% de la muestra tiene enfermedad cardíaca. Un modelo que simplemente predicara "No" para todos obtendría 91.3% de accuracy pero sería clínicamente inútil. Se debe evaluar con Precisión, Recall, F1-score y AUC-ROC.

MODELO SELECCIONADO Y JUSTIFICACIÓN

Tipo de problema: Clasificación binaria (predecir HeartDisease: 0 o 1)

Se entrenaron dos modelos y se comparó su desempeño:

a) Regresión Logística

- Modelo de referencia para clasificación binaria
- Rápido de entrenar, fácil de interpretar (coeficientes como odds ratios)
- Sirve como línea base para evaluar si un modelo más complejo aporta ventaja

b) Random Forest

- Maneja variables numéricas y categóricas mixtas de forma natural
- Captura relaciones no lineales e interacciones entre variables
- Proporciona medida directa de importancia de variables

Modelos descartados:

KNN y SVM: con ~440.000 filas y variables categóricas de alta cardinalidad, serían computacionalmente muy costosos sin ventaja clara de interpretabilidad

Preparación de Datos para el Modelo

Variables predictoras seleccionadas:

- Numéricas: AgeMidpoint, BMI, SleepHours, PhysicalHealthDays, MentalHealthDays
- Categóricas: Sex, GeneralHealth, SmokerStatus, ECigaretteUsage, PhysicalActivities, AlcoholDrinkers, HadDiabetes, HadStroke, HadAsthma, HadKidneyDisease, HadArthritis, HadDepressiveDisorder, HadCOPD, HadSkinCancer, RaceEthnicityCategory, DifficultyWalking

```
variables_numericas_modelo = ['AgeMidpoint', 'BMI', 'SleepHours', 'PhysicalHealthDays', 'MentalHealthDays']

variables_categoricas_modelo = ['Sex', 'GeneralHealth', 'SmokerStatus', 'ECigaretteUsage',
                                'PhysicalActivities', 'AlcoholDrinkers', 'HadDiabetes', 'HadStroke',
                                'HadAsthma', 'HadKidneyDisease', 'HadArthritis', 'HadDepressiveDisorder',
                                'HadCOPD', 'HadSkinCancer', 'RaceEthnicityCategory', 'DifficultyWalking']

predictoras = variables_numericas_modelo + variables_categoricas_modelo
datos_modelo = df[predictoras + ['HeartDisease']].dropna()

print('Filas disponibles para el modelo:', datos_modelo.shape[0])
print('Variables predictoras:', len(predictoras))
```

```
Filas disponibles para el modelo: 438327
Variables predictoras: 21
```

Exclusiones (por qué NO se usaron):

- HadHeartAttack, HadAngina: fuga de información (la variable objetivo se construyó a partir de ellas)
- State: variable administrativa sin valor predictivo clínico para este análisis
- Columnas de tamizaje con muchos "No informado": agregarían ruido

Preprocesamiento:

- One-hot encoding de variables categóricas
- Escalado (StandardScaler) de variables numéricas (solo para Regresión Logística; Random Forest no lo requiere)
- Split 75% entrenamiento / 25% prueba, con stratification en la variable objetivo

Aplicación del modelo.

Se aplican los modelos usando el siguiente código:

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier

modelo_logistico = LogisticRegression(max_iter=1000, class_weight='balanced')
modelo_logistico.fit(x_train_esc, y_train)

modelo_rf = RandomForestClassifier(
    n_estimators=200, max_depth=12, class_weight='balanced',
    random_state=42, n_jobs=-1
)
modelo_rf.fit(x_train, y_train)

print('Modelos entrenados correctamente.')

Modelos entrenados correctamente.
```

Evaluación del modelo e interpretación de los resultados.

Se evaluó el desempeño de ambos modelos en el set de prueba usando múltiples métricas:

	Modelo	Accuracy	Precision	Recall	F1-score	AUC-ROC
0	Regresion Logistica	0.750	0.226	0.773	0.349	0.839
1	Random Forest	0.753	0.227	0.766	0.351	0.836

Interpretación de Resultados

Accuracy 75 %

El 75% de exactitud puede sonar bien, pero es poco informativo aquí por el desbalance. Si el modelo predijera "No" para todo el mundo, obtendría 91.3% de accuracy pero sería clínicamente inútil.

Recall (~77%)

Es la métrica CRUCIAL en este problema. El modelo identifica correctamente al 77% de las personas que SÍ tienen enfermedad cardíaca. En un contexto de tamizaje de salud pública, esto es excelente — por cada 100 personas enfermas, se detectan ~77. El costo es que se envían algunos sanos innecesariamente (falsos positivos).

Precision (~23%)

Por cada 10 personas que el modelo marca como "en riesgo", solo ~2-3 realmente tienen enfermedad cardíaca. Es baja, pero es el trade-off consciente de priorizar el recall con `class_weight="balanced"`. En términos clínicos, algunos sanos pasarían por un chequeo adicional, pero ningún enfermo se iría sin ser detectado.

AUC-ROC (~0.84)

Indica que el modelo discrimina razonablemente bien entre las dos clases, MUY por encima de 0.5 (que sería equivalente a adivinar al azar). Un AUC de 0.84 es considerado bueno en la mayoría de contextos médicos.

COMPARACIÓN DE MODELOS

Ambos modelos presentan un desempeño casi idéntico:

- Diferencia en AUC: 0.839 (Regresión Logística) vs 0.836 (Random Forest) = 0.003 (insignificante).
- Diferencia en Recall: 0.773 (Regresión Logística) vs 0.766 (Random Forest) = 0.007 (insignificante).

Dado que ambos modelos alcanzan un desempeño prácticamente igual e incluso la Regresión Logística tiene un recall y un AUC ligeramente superiores—, se **recomienda usar la Regresión Logística como modelo final**, porque:

1. Es más rápida de entrenar y aplicar.
2. Es mucho más fácil de explicar a decisores clínicos y de salud pública (los coeficientes son odds ratios directamente interpretables).
3. No sacrifica precisión predictiva respecto a Random Forest.

Hallazgos, patrones e insights

A partir del EDA y las pruebas estadísticas anteriores:

- 1. La edad es el factor más determinante.** La prevalencia de enfermedad cardíaca sube de forma casi monótona con la edad, de menos del 2% en menores de 30 años a más del 20% en mayores de 80 consistente con el envejecimiento como factor de riesgo no modificable.
- 2. Diferencia significativa por sexo.** Los hombres muestran una prevalencia aproximadamente 2 veces más alta que las mujeres (12-14% vs 5-7%), asociación confirmada estadísticamente.
- 3. Percepción de salud general y diabetes son los predictores categóricos más fuertes.** **General Healths** y **Hadiabetes** tienen el estadístico más alto: quienes reportan salud "Poor" tienen 30% de prevalencia, frente a 1% en quienes reportan "Excellent".
- 4. El tabaquismo importa, en forma escalonada.** Nunca haber fumado se asocia a la menor prevalencia (~6-7%), ser fumador actual a la más alta (~12-14%), y los exfumadores quedan en una posición intermedia (~10-11%).
- 5. La actividad física tiene un efecto protector.** Quienes hacen actividad física reportan menor prevalencia (~7-8%) que quienes no la hacen (~11-12%).
- 6. El BMI es significativamente mayor en el grupo con enfermedad cardíaca,** confirmado por la prueba de Mann-Whitney U, aunque la diferencia numérica sea pequeña.

7. Las correlaciones lineales simples son débiles, lo que sugiere que el riesgo cardíaco depende de la combinación de múltiples factores (edad, sexo, condiciones clínicas, comportamientos) más que de una sola variable — esto justifica usar un modelo capaz de capturar relaciones no lineales e interacciones.


8. El dataset está desbalanceado, con solo ~8.7% de casos positivos. Un modelo que prediga "No" para todos obtendría 91.3% de accuracy pero sería clínicamente inútil, de ahí la necesidad de evaluar con Precisión, Recall, F1-score y AUC-ROC.

Interpretación de los factores más importantes

Random Forest y la Regresión Logística coinciden en señalar GeneralHealth (especialmente "Poor" y "Fair"), la edad (AgeMidpoint), el sexo masculino, y antecedentes de accidente cerebrovascular (HadStroke) o EPOC (HadCOPD) como los factores de mayor peso.

En el lado contrario, "nunca haber fumado" es la categoría que más reduce el riesgo relativo frente a fumar actualmente.

Ambos modelos obtienen un desempeño muy similar ($AUC \approx 0.84$ vs 0.84). Dado que sus resultados son comparables, se recomienda la Regresión Logística como modelo final por ser igual de efectiva y mucho más fácil de explicar e interpretar clínicamente (odds ratios) frente a decisores no técnicos — justo el tipo de comunicación que pide un proyecto de salud pública.



Conclusiones

La enfermedad cardíaca en esta muestra (BRFSS 2022) tiene una prevalencia de ~8.7 %, y está asociada de forma estadísticamente significativa con la edad, el sexo, la percepción de salud general, la diabetes, el tabaquismo y el nivel de actividad física (todas las pruebas χ^2 y Mann-Whitney realizadas rechazaron H_0 con $p < 0.001$).

La edad y la percepción de salud general son, de forma consistente en ambos modelos, los factores más asociados a la enfermedad cardíaca.

Un modelo relativamente simple (Regresión Logística con variables demográficas, clínicas y conductuales) alcanza un poder de discriminación aceptable ($AUC \approx 0.84$) sin necesidad de un modelo más complejo como Random Forest, que obtuvo un desempeño prácticamente idéntico.

El principal límite del modelo es la baja precisión (muchos falsos positivos) que resulta de priorizar detectar a la mayoría de personas enfermas (alto recall) en un problema con clases desbalanceadas — es una decisión razonable en un contexto de tamizaje de salud pública, pero debe comunicarse con claridad.

Recomendaciones:

Usar el modelo como una herramienta de tamizaje (para priorizar a quién ofrecer un chequeo cardiovascular más detallado), nunca como diagnóstico definitivo, dado su nivel de precisión.

Priorizar campañas de prevención dirigidas a personas mayores de 55 años, hombres, personas con diabetes y quienes reportan mala salud general — los grupos de mayor riesgo identificados.

Explorar en un trabajo futuro variables adicionales (acceso a servicios de salud, nivel socioeconómico) y técnicas de balanceo de clases (SMOTE, ajuste de umbral de decisión) para mejorar la precisión sin sacrificar tanto el recall.

Para las variables de tamizaje opcional que quedaron con la categoría "No informado" (HIV, tétano, neumococo, etc.), sería valioso indagar si el faltante está relacionado con acceso a servicios de salud, lo cual podría ser en sí mismo un hallazgo relevante para políticas públicas.

Referencias

CDC — Behavioral Risk Factor Surveillance System (BRFSS). <https://www.cdc.gov/brfss/>

Kaggle — Indicators of Heart Disease (2022 UPDATE).

<https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease>

Scikit-learn Documentation — Model Selection and Evaluation. <https://scikit-learn.org/>

Pandas Documentation — Data manipulation and analysis. <https://pandas.pydata.org/>

American Heart Association — Heart Disease and Stroke Statistics. <https://www.heart.org/>