

Predicción de Riesgo Cardiovascular

Factores demográficos, clínicos y conductuales asociados a la enfermedad cardíaca, a partir de la encuesta BRFSS 2022.

Presentado por: Juan Sebastian Garcia, Julian David Sanabria, Wendy Natalia Vega, Laura Daniela Rivera

Docente: Camila Silva Gómez



Lo que veremos hoy

01

Planteamiento y objetivo

Contexto del problema y objetivos del proyecto

02

Los datos

Fuente BRFSS 2022 y comprensión de variables

03

Limpieza y preparación

Proceso completo de depuración del dataset

04

Análisis exploratorio (EDA)

Patrones, pruebas estadísticas y hallazgos

05

Modelado predictivo

Regresión Logística vs. Random Forest

06

Conclusiones y recomendaciones

Hallazgos clave y próximos pasos

01

Planteamiento y objetivo del proyecto

El punto de partida: por qué importa predecir el riesgo cardiovascular y qué buscamos responder con los datos.

Contexto y pregunta de investigación

Contexto

Las enfermedades cardiovasculares son una de las principales causas de muerte a nivel mundial. Parte del riesgo se asocia a factores modificables (hábitos, actividad física, tabaquismo) y otros no modificables (edad, sexo, antecedentes clínicos).

Pregunta de investigación

¿Cuáles son los factores demográficos, clínicos y conductuales que mejor predicen la presencia de enfermedad cardíaca en adultos? ¿Es posible construir un modelo que identifique personas en riesgo con exactitud aceptable?

Diseñar estrategias de prevención y detección temprana adaptadas a poblaciones específicas.

OBJETIVO GENERAL

Analizar los factores demográficos, clínicos y conductuales asociados a la enfermedad cardíaca, y construir un modelo capaz de predecir su probabilidad, basado en la encuesta BRFSS 2022.

Objetivos específicos

1

Limpiar, validar y preparar la base de datos siguiendo el ciclo completo de preprocesamiento.

2

Caracterizar la muestra mediante análisis estadístico descriptivo de variables numéricas y categóricas.

3

Explorar relaciones entre variables clínicas/conductuales y la enfermedad cardíaca mediante EDA y pruebas estadísticas.

4

Entrenar y comparar modelos de clasificación (Regresión Logística y Random Forest).

5

Evaluar el desempeño del modelo e interpretar los factores de mayor importancia.


6

Formular conclusiones y recomendaciones aplicables a políticas de salud pública.

02

Búsqueda y comprensión de los datos

De dónde vienen los datos, por qué son confiables y qué variables describen a cada persona encuestada.



Indicators of Heart Disease · BRFSS 2022

Fuente

Publicado en Kaggle a partir de la encuesta anual BRFSS (Behavioral Risk Factor Surveillance System) que el CDC aplica telefónicamente a cientos de miles de adultos en EE. UU.

Justificación

- Encuesta oficial, ~445.000 registros, variables ya validadas por el CDC.
- Mismo dataset (heart_2022_with_nans.csv) usado como referencia en el curso.
- Contiene valores faltantes reales y variables numéricas, binarias y multiclase — ideal para el ciclo completo de Ciencia de Datos.

445.132

Filas iniciales

40

Variables (columnas)

3

Tipos de variable
(numéricas, binarias, multiclase)

Grupos de variables analizadas

- **Demográficas** State, Sex, AgeCategory, RaceEthnicityCategory
- **Salud física y mental** GeneralHealth, PhysicalHealthDays, MentalHealthDays, SleepHours
- **Comportamiento y estilo de vida** PhysicalActivities, SmokerStatus, ECigaretteUsage, AlcoholDrinkers
- **Antropometría** HeightInMeters, WeightInKilograms, BMI
- **Antecedentes clínicos** HadHeartAttack, HadAngina, HadStroke, HadDiabetes, HadAsthma, HadCOPD, HadKidneyDisease, HadArthritis, HadDepressiveDisorder, HadSkinCancer

03

Limpieza y preparación de los datos

Seis etapas ordenadas para pasar de datos crudos a un dataset confiable y sin faltantes.



Se sigue un orden estricto de seis etapas

1

Nombres de columnas

Sin cambios: el archivo del CDC ya viene bien formateado.

2

Duplicados exactos

157 duplicados encontrados y eliminados (445.132 → 444.975 filas).

3

Texto y categorías

Sin variantes equivalentes: el archivo ya estaba estandarizado.

4

Valores imposibles

Rangos válidos por variable; 10 valores fuera de rango marcados como NaN.

5

Valores faltantes

Estrategia diferenciada según tipo y % de faltantes (ver siguiente slide).

6

Verificación final

438.327 filas × 40 columnas, 0 nulos totales.

Estrategia diferenciada según tipo de variable

Variable objetivo	<i>HadHeartAttack, HadAngina</i>	Eliminación de filas — no se imputan para no introducir sesgo. Se eliminaron 3.065 y 4.405 filas nulas respectivamente.
Numéricas continuas	<i>PhysicalHealthDays, SleepHours, BMI, etc.</i>	Imputación con mediana: todas presentan asimetría, la mediana es más robusta que la media.
Categóricas con <10% faltantes	<i>Sex, GeneralHealth, SmokerStatus, AgeCategory...</i>	Imputación con moda (categoría más frecuente). Con faltantes bajos es una aproximación segura.
Categóricas de tamizaje (≥10% faltantes)	<i>ChestScan, HIVTesting, TetanusLast10Tdap, CovidPos...</i>	Categoría explícita "No informado": preserva la información sin inventar una respuesta.

Dataset listo para el análisis

445.132

Filas iniciales

438.327

Filas finales limpias

40

Columnas

0

Nulos totales

```
# Verificación final de limpieza
print('Filas finales limpias :', df.shape[0])
print('Nulos totales          :', df.isnull().sum().sum())
```

```
Filas finales limpias : 438327
```

```
Nulos totales          : 0
```


04

Análisis exploratorio de datos (EDA)

Patrones, distribuciones y pruebas estadísticas que revelan qué variables se asocian con la enfermedad cardíaca.



Un dataset claramente desbalanceado



399.038

personas SIN enfermedad cardíaca (91.3%)


38.624

personas CON enfermedad cardíaca (8.7%)


⚠ **Advertencia para el modelado**

Es clínicamente esperado (no todos tienen un evento cardíaco), pero la exactitud (accuracy) sola puede ser engañosa. Deben evaluarse precisión, recall y AUC-ROC.

La edad es el factor más determinante




Edad: de <2% en menores de 30 años a >20% en mayores de 80. Patrón casi monótono y consistente con el envejecimiento como factor de riesgo no modificable.




Sexo: los hombres muestran una prevalencia ~2 veces mayor que las mujeres (12-14% vs 5-7%), diferencia estadísticamente significativa.

Tres predictores conductuales fuertes



GeneralHealth es uno de los predictores categóricos más fuertes (Poor ≈30% vs. Excellent ≈1-2%). El tabaquismo muestra un patrón escalonado y la actividad física un claro efecto protector. Además, el BMI es significativamente mayor en personas con enfermedad cardíaca (mediana 29.5 vs. 26.8).

Matriz de Correlacion



- Multicolinealidad: BMI y peso ($r = 0.85$)
- Peso y altura ($r = 0.46$)
- Salud física y mental vinculadas ($r = 0.31$)
- Edad y salud mental ($r = -0.18$)

- $r = +1 \rightarrow$ correlación positiva perfecta (cuando una sube, la otra sube siempre, de forma exactamente proporcional)
- $r = 0 \rightarrow$ no hay relación lineal
- $r = -1 \rightarrow$ correlación negativa perfecta (cuando una sube, la otra baja siempre)

Pruebas Chi-cuadrado de independencia

H0: la variable categórica es independiente de HeartDisease. **H1:** existe asociación. Nivel de significancia $\alpha = 0.05$

Variable	Chi²	p-valor	Conclusión
GeneralHealth	25,329.3	≈ 0	Se rechaza H0 (hay asociación)
HadDiabetes	13,874.4	≈ 0	Se rechaza H0 (hay asociación)
SmokerStatus	4,759.4	≈ 0	Se rechaza H0 (hay asociación)
PhysicalActivities	4,030.1	≈ 0	Se rechaza H0 (hay asociación)
Sex	2,138.7	≈ 0	Se rechaza H0 (hay asociación)
RaceEthnicityCategory	1,028.4	2.55e-221	Se rechaza H0 (hay asociación)

Conclusión: todas las variables categóricas están asociadas de forma estadísticamente significativa con la enfermedad cardíaca. GeneralHealth y HadDiabetes son los predictores categóricos más fuertes.

Ocho patrones clave antes de modelar

1

La edad es el factor más determinante (efecto casi monótono).

2

Los hombres duplican la prevalencia de las mujeres.

3

GeneralHealth y HadDiabetes son los predictores categóricos más fuertes.

4

El tabaquismo importa en forma escalonada (nunca < actual < exfumador).

5

La actividad física tiene un efecto protector claro.

6

El BMI es significativamente mayor en personas con enfermedad cardíaca (Mann-Whitney, $p < 0.001$).

7

Las correlaciones lineales simples son débiles: el riesgo depende de la combinación de variables, no de una sola.

8

Dataset desbalanceado (8.7%): la accuracy sola puede ser engañosa; se requieren métricas alternativas.

05

Selección y evaluación del modelo

Dos modelos de clasificación binaria puestos a prueba: interpretabilidad frente a capacidad de capturar relaciones complejas.



Regresión Logística vs. Random Forest

Regresión Logística

- Modelo de referencia para clasificación binaria
- Rápido de entrenar y fácil de interpretar (odds ratios)
- Sirve como línea base para evaluar modelos más complejos

Random Forest

- Maneja variables numéricas y categóricas mixtas
- Captura relaciones no lineales e interacciones
- Da una medida directa de importancia de variables

Modelos descartados

KNN y SVM: con ~440.000 filas y variables categóricas de alta cardinalidad, serían computacionalmente muy costosos, sin ventaja clara de interpretabilidad.

21 variables predictoras, codificación y split

```
variables_numericas = ['AgeMidpoint', 'BMI', 'SleepHours', ...]  
variables_categoricas = ['Sex', 'GeneralHealth', ...]
```

```
X = pd.get_dummies(datos[predictoras],  
                  columns=variables_categoricas)
```

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.25, stratify=y)
```

21

variables predictoras (5 numéricas + 16 categóricas)

75% / 25%

split entrenamiento / prueba, con stratification

Exclusiones deliberadas

- **HadHeartAttack, HadAngina:** fuga de información (la variable objetivo se construyó a partir de ellas).
- **State:** variable administrativa sin valor predictivo clínico.
- **Columnas de tamizaje ('No informado'):** agregarían ruido al modelo.

Comparación de métricas en el set de prueba

Modelo	Accuracy	Precision	Recall	F1-score	AUC-ROC
Regresión Logística	0.750	0.226	0.773	0.349	0.839
Random Forest	0.753	0.227	0.766	0.351	0.836

Recall ≈ 77%

Métrica CRUCIAL: identifica correctamente al 77% de las personas que sí tienen la enfermedad. Excelente para tamizaje de salud pública.

Precision ≈ 23%

Trade-off consciente: de cada 10 marcados en riesgo, ~2-3 realmente la tienen. Se prioriza no dejar enfermos sin detectar.

AUC-ROC ≈ 0.84

El modelo discrimina bien entre clases, muy por encima de 0.5 (azar). Un valor considerado bueno en contextos médicos.

Desempeño casi idéntico → gana la interpretabilidad

Diferencias entre modelos

AUC: 0.839 (Log) vs 0.836 (RF) → diferencia de 0.004, insignificante

Recall: 0.773 (Log) vs 0.766 (RF) → diferencia de -0.002, insignificante

Se recomienda la Regresión Logística como modelo final porque:

- Es más rápida de entrenar y aplicar
- Mucho más fácil de explicar a decisores de salud pública (odds ratios directamente interpretables)
- No sacrifica precisión predictiva frente a Random Forest

Factores de mayor peso

Odds ratio > 1 (aumentan el riesgo):

- GeneralHealth: Poor (5.08x) y Fair (4.02x)
- HadStroke (3.21x)
- AgeMidpoint (2.70x)
- Sex Male (2.21x)
- HadKidneyDisease (1.80x), HadCOPD (1.68x)

Menor riesgo relativo:

"Nunca haber fumado" es la categoría que más reduce el riesgo frente a fumar actualmente.

06

Conclusiones y recomendaciones

Qué aprendimos del análisis y cómo se traduce en decisiones concretas de salud pública.



Principales hallazgos del proyecto



- ✓ La enfermedad cardíaca en esta muestra (BRFSS 2022) tiene una prevalencia de ~8.7%.
- ✓ Está asociada de forma estadísticamente significativa con edad, sexo, percepción de salud, diabetes, tabaquismo y actividad física (todas las pruebas con $p < 0.001$).
- ✓ La edad y la percepción de salud general son, en ambos modelos, los factores más asociados a la enfermedad.
- ✓ Un modelo relativamente simple (Regresión Logística) alcanza un poder de discriminación aceptable (AUC ≈ 0.84), sin necesidad de un modelo más complejo.
- ✓ El principal límite es la baja precisión (muchos falsos positivos), resultado consciente de priorizar el recall en un problema desbalanceado.

De los hallazgos a la acción

Usar como tamizaje, no diagnóstico

Priorizar a quién ofrecer un chequeo cardiovascular más detallado, nunca como diagnóstico definitivo dado su nivel de precisión.

Explorar variables adicionales

Acceso a servicios de salud y nivel socioeconómico, junto con técnicas de balanceo de clases (SMOTE, ajuste de umbral).

Focalizar campañas de prevención

Dirigidas a personas mayores de 55 años, hombres, personas con diabetes y quienes reportan mala salud general.

Investigar el missingness informativo

Indagar si el faltante en variables de tamizaje opcional (VIH, tétano, neumococo) se relaciona con acceso a servicios de salud.

Referencias

- American Heart Association. (s. f.). Heart disease and stroke statistics. <https://www.heart.org/>
- Centers for Disease Control and Prevention. (s. f.). Behavioral Risk Factor Surveillance System (BRFSS). U.S. Department of Health and Human Services. <https://www.cdc.gov/brfss/>
- Pytlak, K. (2023). Indicators of Heart Disease (2022 UPDATE) [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease>
- Pandas Development Team. (s. f.). Pandas documentation: Data manipulation and analysis. <https://pandas.pydata.org/>
- Scikit-learn Developers. (s. f.). Scikit-learn documentation: Model selection and evaluation. <https://scikit-learn.org/>